

PREGUNTA 1: Definir IA

La IA es un campo de la informática que se enfoca en crear máquinas inteligentes que puedan realizar tareas que normalmente requieren inteligencia humana, como aprender, razonar y resolver problemas.

PREGUNTA 2: IA Local vs IA Nube

Qué hacen, parámetros, servicios de enfoque.

¿Qué hacen?

IA Local: Ejecuta la inferencia y el procesamiento directamente en el hardware del usuario o en servidores privados (utilizando CPU, GPU o NPU locales). Opera sin conexión a internet y garantiza que los datos nunca salgan del dispositivo.

IA en la Nube: Ejecuta los modelos en centros de datos remotos masivos (clústeres de servidores de alto rendimiento). El usuario envía peticiones mediante conexión a internet (APIs o interfaces web) y recibe la respuesta procesada de forma remota.

Tamaño y parámetros típicos

IA Local: Utiliza modelos compactos y medianos, habitualmente entre 0.5B (500 millones) y 14B de parámetros (máximo 70B en servidores de trabajo avanzados con múltiples GPUs). Depende fuertemente de técnicas de cuantización (INT4 u INT8) para reducir el consumo de memoria VRAM y RAM.

IA en la Nube: Utiliza modelos frontera gigantes, habitualmente desde 70B hasta cientos de miles de millones o billones de parámetros (arquitecturas densas o MoE / Mixture of Experts), las cuales requieren petabytes de cómputo y memoria imposible de replicar en un equipo personal.

Servicios de enfoque (Herramientas y plataformas representativas)

Ecosistema de IA Local:

Runtimes y gestores de ejecución: Ollama, LM Studio, vLLM, llama.cpp, AnythingLLM.

Modelos base: Llama (Meta), Mistral, Phi (Microsoft), Gemma (Google), DeepSeek, Qwen.

Hardware de enfoque: NPUs integradas en portátiles/móviles, GPUs dedicadas (NVIDIA RTX, Apple Silicon Neural Engine).

Ecosistema de IA en la Nube:

Proveedores de infraestructura/servicios administrados: OpenAI API, Google Cloud Vertex AI, Amazon Bedrock, Microsoft Azure AI Foundry.

Modelos base: GPT-4 / modelos frontier de OpenAI, Claude, Gemini Ultra/Pro.

Otras características comparadas en la tabla:

CARACTERÍSTICA	IA Local	IA en la Nube
Conexión	Offline	Online
Privacidad y Datos	Máxima pues los datos no salen del equipo	Depende de las políticas del proveedor
Latencia de Red	Nula / tiempo real	Variable (depende de la red y cola del servidor)
Modelo de Costo	Fijo (inversión inicial en hardware)	Variable (pago por uso / tokens consumidos)
Escalabilidad	Limitada por el hardware local	Elástica e inmediata a millones de consultas
Casos de uso	Datos confidenciales/médicos, robótica, transcripción en tiempo real, entornos aislados	Razonamiento complejo, análisis masivo, uso ocasional de usuarios en todo el mundo

PREGUNTA 3: 5 Tipos de IA

GPT-4 (OpenAI): Sistema de lenguaje de gran escala (LLM) de frontera, enfocado en deducción lógica avanzada, procesamiento crítico y síntesis de texto conversacional.

Gemini (Google): Arquitectura multimodal nativa concebida para la interpretación, razonamiento e integración simultánea de información textual, auditiva, visual, código informático y video.

Llama 3 (Meta): Modelo base de código abierto caracterizado por su alto rendimiento, optimizado para la personalización e implementación por parte de investigadores y creadores de software.

Midjourney: Motor generativo basado en algoritmos de difusión, orientado a la producción de piezas visuales, arte digital e ilustraciones complejas mediante instrucciones escritas.

YOLO (You Only Look Once): Red neuronal de visión artificial de ultra baja latencia, especializada en el rastreo, localización e identificación de elementos en transmisiones de vídeo e imágenes en tiempo real.

PREGUNTA 4: Tipos de IA locales y Cuales de pueden ejecutar en Pc

Tipos de IA Local

1. **Modelos de Lenguaje (Texto/Chatbots):** Como Llama 3 (Meta), Mistral o Gemma. Se ejecutan con programas muy fáciles de usar como **Ollama** o **LM Studio**. Dependen de la cantidad de memoria RAM.
2. **Modelos de Difusión (Generación de Imágenes):** Como Stable Diffusion (SD 1.5). Utilizan programas como **Automatic1111** o **ComfyUI**. Requieren casi obligatoriamente una tarjeta gráfica dedicada (GPU), preferiblemente de NVIDIA para aprovechar la tecnología CUDA.
3. **Modelos de Audio/Visión:** Como **Whisper** (transcripción de audio a texto) o **YOLO** (detección de objetos). Suelen ejecutarse bastante bien en el procesador (CPU) o apoyándose en la gráfica.

COMPUTADORES:

1. Ryzen 5 8600G | 16 GB de RAM DDR5

- **Texto (LLMs):** Muy capaz. Podrás correr modelos pequeños y muy inteligentes (de 7B a 8B parámetros, como **Llama 3 8B**) de forma fluida. La memoria RAM DDR5 es un punto clave aquí, ya que su alta velocidad permite que el procesador lea la IA mucho más rápido que en versiones anteriores.
- **Imágenes:** Muy limitado. Al depender de gráficos integrados y no tener una GPU NVIDIA, generar imágenes tomará mucho tiempo (varios minutos por imagen) usando la CPU.
- **Audio (Whisper):** Lo ejecutará sin problemas.

2. i5 12500H | 24 GB RAM DDR4 | GPU RTX 3050

- **Texto (LLMs):** Excelente capacidad y velocidad. Gracias a los 24 GB de RAM, puedes cargar modelos un poco más grandes. Además, la RTX 3050 te permite descargar parte del esfuerzo de la CPU hacia la gráfica, logrando respuestas más rápidas.
- **Imágenes: Esta es tu mejor opción para diseño visual.** La RTX 3050 (NVIDIA) cuenta con *Tensor Cores* y *CUDA*, lo que te permite ejecutar Stable Diffusion 1.5 de manera fluida. Debido a que esta gráfica suele tener 4GB de VRAM, estarás limitado a generar imágenes de 512x512 píxeles de resolución base.
- **Audio (Whisper):** Volando. Puede usar la aceleración de la tarjeta gráfica para transcribir audios largos en segundos.

3. Ryzen 7 5700 | 24 GB DDR4 | GPU GTX 1650

- **Texto (LLMs):** Similar al PC 2 en capacidad gracias a los 24 GB de RAM. Podrás instalar los mismos modelos de lenguaje, aunque la aceleración será levemente menor porque la GTX 1650 es de una arquitectura más antigua.
- **Imágenes:** Puede correr Stable Diffusion, pero **sufrirá un poco**. La GTX 1650 tiene 4GB de VRAM pero carece de la tecnología moderna (*Tensor Cores*) de la RTX 3050, por lo que el tiempo para generar una imagen será de 3 a 5 veces mayor que en el PC 2. Se recomienda usar **ComfyUI**, que optimiza mejor los recursos limitados.
- **Audio (Whisper):** Lo ejecutará sin inconvenientes.